

Projet - Base de donnée Facebook100

Le Jupyter Notebook contenant les codes associé à ce compte-rendu sont disponible ici :


- [La github classroom](#)
- [Le repo git](#)

Question 2 :

Premièrement, on s'intéresse aux réseaux d'étudiants des universités de Caltech, MIT et Johns Hopkins et leurs répartitions.

Question a)

Dans un premier temps, on trace les histogrammes associés à la distribution des degrés pour chacune des trois universités :



- On a ici trois distributions de degré typiques des réseaux sociaux réels : **fortement asymétriques, majorité de nœuds faiblement connectés**, et une **minorité ayant un degré élevé**. Cela est cohérent avec le cadre de l'étude, vu que ce type de distribution est caractéristique des réseaux de type scale-free.

- Ces trois graphes peuvent être vus comme des modèles du même phénomène social, mais à différentes échelles :

- *Caltech* représente un réseau de petite taille, avec une distribution de degré plus compacte. La majorité des nœuds ont un faible degré, et seuls quelques-uns dépassent les 100 connexions.

- *MIT* et surtout *Johns Hopkins* illustrent des réseaux de plus grande échelle, avec des distributions plus étalées. On y observe davantage de longues traînes, ce qui indique la présence d'un nombre significatif de nœuds très connectés (jusqu'à près de 900 pour Hopkins).

- Cette différence d'échelle accentue les effets de croissance préférentielle : plus le réseau est grand, plus il a de chances de contenir des hubs très connectés.

Question b)

On calcule ensuite les données suivantes pour chacune des universités :

Caltech Network Metrics:

Global Clustering Coefficient: 0.40929439048517224

Mean Local Clustering Coefficient: 0.2912826901150874

Edge Density: 0.05640442132639792

MIT Network Metrics:

Global Clustering Coefficient: 0.271218741950132

Mean Local Clustering Coefficient: 0.18028845093502427

Edge Density: 0.012118119495041378

Johns Hopkins Network Metrics:

Global Clustering Coefficient: 0.26839307371293514

Mean Local Clustering Coefficient: 0.19316123901594015

Edge Density: 0.013910200162372396

A partir de ces résultats, on tire que :

- Les réseaux sont très épars (faible densité d'arêtes), d'où peu de liens sont présents au vu du nombre de connexions : typique des réseaux sociaux réels à grande échelle.

- On remarque que le réseau de *Caltech* a un coefficient de clustering global et local nettement plus élevé alors qu'il est bien plus petit : les amis d'un individu ont plus de chances d'être eux-mêmes amis entre eux.

- La communauté de *Caltech* est donc construite de pleins de petits groupes très connectés.


- A l'inverse, on remarque que les réseaux du *MIT* et de *Johns Hopkins*, bien que beaucoup plus grands, ont un clustering plus faible : la structure globale est plus dispersée, avec moins de boucles locales.

- Les communautés de *MIT* et *Hopkins* sont plus éclatées, avec des liens répartis à travers des sous-communautés plus lâches.

- D'où *Caltech* illustre un réseau social plus serré et communautaire, tandis que *MIT* et *Hopkins* représentent des réseaux plus vastes et moins denses.

Question c)

Pour finir cette partie, on trace le diagramme du coefficient de clustering local en fonction du degré pour chacune des universités





On en tire que, dans les trois cas, on observe une tendance inverse entre le degré d'un nœud et son coefficient de clustering local. Les nœuds faiblement connectés ont souvent un clustering élevé, d'où "les amis de mes amis sont mes amis"

- Caltech présente le graphe le moins compact.


- MIT présente une décroissance plus continue.


- Johns Hopkins présente des points isolés.



Question 3 :

On souhaite maintenant étudier l'assortiment des réseaux selon différents indicateurs.





Interprétation

1. du statut (`student_fac`)

- sur le graphe : L'assortativité varie entre environ 0.1 et 0.5, avec une majorité de valeurs clairement au-dessus de 0. Il n'y a pas de tendance visible par rapport à la taille du réseau.
- sur l'histogramme : La distribution est centrée autour de 0.3, ce qui indique une forte homogamie (les étudiants se lient aux autres étudiants, de même pour les professeurs).
- Interprétation : Cette forte homogamie peut s'expliquer par la séparation institutionnelle entre étudiants et enseignants.

2. de la majeure (`major_index`)

- sur le graphe : Les valeurs sont relativement faibles (majoritairement entre 0.02 et 0.12), sans tendance claire selon la taille.
- sur l'histogramme : Distribution centrée autour de 0.05, indiquant une faible mais présente homogamie.
- Interprétation : Cela reflète probablement le fait que les étudiants ont tendance à interagir davantage avec des personnes qui partagent leurs cours, projets...

3. du degré du sommet (`vertex_degree`)

- sur le graphe : Les valeurs sont proches de 0, avec plusieurs réseaux affichant une assortativité légèrement négative.
- sur l'histogramme : Distribution centrée autour de 0, avec une queue vers les valeurs négatives.
- Interprétation : Cela suggère une absence de préférence forte en termes de degré.

4. du dortoir (`dorm`)

- sur le graphe : Assortativité également faible à modérée (valeurs allant de légèrement négatives à environ 0.3).
- sur l'histogramme : Distribution centrée vers 0.1-0.15, ce qui indique une modérée homogamie.
- Interprétation : Rien de surprenant car les dortoirs sont des espaces partagés et de socialisation.

5. du Genre (`gender`)

- sur le graphe : Les valeurs sont très proches de 0, avec une légère dispersion autour de cette valeur (positives et négatives).
- sur l'histogramme : Distribution centrée autour de 0.02.
- Interprétation : Cela indique une très faible homogamie de genre. Certaines écoles montrent une légère hétérogamie (ce qui peut refléter des interactions genrées, comme les relations amoureuses hétérosexuelles). En moyenne, la tendance est vers une homogamie très modérée.

D'où on peut classer les attributs de la plus à la moins forte influence :

1. Statut 2. Dortoir 3. Majeure 4. Genre 5. Degré

Question 4 :

On cherche maintenant à prédire certains liens sur un graphe grâce à la méthode des voisins communs, la méthode Adamic-Adar et la méthode Jaccard.

Question d)

Après écriture des algorithmes, on teste la précision de la prédiction sur les universités de Caltech et MIT. Au vu des résultats, on peut conclure que la méthode des voisins Common Neighbors et Adamic-Adar sont bien plus efficaces que Jaccard pour prédire les liens manquants dans les graphes sociaux de Caltech et MIT. On remarque par ailleurs que les trois méthodes sont globalement plus précises quand le nombre d'arêtes supprimées f augmente et k diminue, à l'exception de la méthode de Jaccard qui fonctionne mieux à haut k sur le graphe de MIT.

- Par ailleurs, on retrouve que :
 - Caltech possède un réseau plus fragmenté (les performances sont plus faibles).
 - MIT possède un réseau plus dense, où les amis partagent souvent des cercles communs (précisions de Common Neighbors et Adamic-Adar plus élevées, surtout pour de faibles valeurs de k).

Question 5 :

On cherche maintenant à trouver des étiquettes manquantes sur un graphe, et à calculer la précision de cette recherche.

Question d)

Après implémentation de l'algorithme, et du test sur Caltech, on obtient les résultats suivants :

	fraction removed		
	0.1	0.2	0.3
<i>Caltech</i>			
<i>Major</i>	0.135	0.134	0.139
<i>Dorm</i>	0.412	0.410	0.411
<i>Gender</i>	0.082	0.082	0.0788

Les scores obtenus sont globalement plus faibles que ceux donnés dans le sujet, surtout pour le genre.

Je pense que ça peut venir du nombre d'itérations (fixé à 100). Peut-être qu'il n'est pas suffisant pour bien faire converger la propagation des labels, surtout sur certaines classes peu connectées. Le choix du graphe utilisé peut aussi expliquer les écarts. Le sujet utilise les données de Duke, alors c'est MIT qui a été utilisé dans les tests, et on a vu que certaines populations ont des réseaux différents selon des critères différents.

Certains labels sont aussi plus faciles à prédire car ils sont plus fortement corrélés à la structure du graphe. Par exemple, les étudiants vivant dans le même dortoir sont souvent connectés entre eux, ce qui facilite la propagation correcte de l'attribut `dorm`, contrairement à `gender` qui peut être plus réparti aléatoirement dans le réseau.

Question 6 :

On nous demande ici de formuler une hypothèse, puis de la mettre à l'épreuve

Question a)

On émet donc l'hypothèse que "les étudiants vivant dans le même dortoir sont plus susceptibles de former des communautés fortement connectées, comparativement aux étudiants partageant simplement une même majeure"

Question b)

Après écriture du programme, on obtient les résultats suivants pour les universités de Caltech et MIT :

```
NMI communauté vs dortoir pour Caltech : 0.534
NMI communauté vs majeure pour Caltech : 0.104
NMI communauté vs dortoir pour MIT : 0.238
NMI communauté vs majeure pour MIT : 0.036
```

Question c)

Les résultats suggèrent que les communautés détectées sont davantage alignées avec les groupes de dortoirs qu'avec les majeures des étudiants, pour Caltech ($0.534 > 0.104$) comme pour MIT ($0.238 > 0.036$). D'où notre hypothèse selon laquelle les communautés sociales seraient mieux représentées par les dortoirs semble être vérifiée !